

Project Report: AniFans - Data Analysis

Group Name: AniFans **Group Members:**

- Luca Dalla Villa (1097708)
 - Bilal Benslimane (1094638)
 - Luca Angela (1100008)
-

1. Introduction

Questo progetto mira a fornire un'analisi approfondita e visuale del panorama Anime, rivolgendosi a due target specifici: Fan e Giornalisti (considerati utenti esperti). Utilizzando un set di Jupyter Notebook, abbiamo elaborato 12 dataset CSV forniti, eseguendo operazioni di pulizia, analisi statistica e visualizzazione geospaziale. L'obiettivo è trasformare dati grezzi in insight significativi utilizzando un approccio Python-centric integrato con tecnologie SQL.

2. Data Management & Persistence (SQLAlchemy & DuckDB)

Solution (Design and Motivations)

Per gestire l'importazione e l'interrogazione efficiente dei dataset (in particolare quelli voluminosi come `ratings.csv`), abbiamo integrato **DuckDB** all'interno del nostro flusso Jupyter e una connessione database **Postgres** per l'utilizzo dei dati ricavati dai file csv.

Utilizzando `psycopg2-binary` e `python-dotenv`, abbiamo configurato connessioni sicure al database per simulare un ambiente di produzione reale. Abbiamo scelto DuckDB per la sua capacità di eseguire query SQL analitiche veloci direttamente sui file CSV/Pandas DataFrames senza il sovraccarico di un server database completo, mentre SQLAlchemy ci ha permesso di mantenere un'astrazione orientata agli oggetti (ORM) dove necessario.

Issues

La sfida principale è stata la gestione dei tipi di dati durante l'importazione massiva dai CSV al formato SQL, specialmente per colonne contenenti valori nulli o formattazioni inconsistenti.

Requirements

Questa soluzione soddisfa il requisito di analizzare i dati garantendo prestazioni superiori rispetto alla semplice manipolazione in memoria, specialmente per aggregazioni complesse richieste dall'analisi per "Esperti".

Limitations

L'uso di un motore SQL all'interno di un notebook richiede che l'ambiente locale abbia risorse sufficienti (RAM) se si lavora con database in-memory.

3. Data Cleaning & Processing (Pandas & NumPy)

Solution (Design and Motivations)

Abbiamo utilizzato **Pandas** e **NumPy** come spina dorsale per la manipolazione dei dati. Il processo di pulizia ha incluso:

1. Gestione dei valori mancanti (NaN) in dataset critici come `Details.csv`.
2. Normalizzazione dei formati di data.
3. Merging (join) tra diverse tabelle (es. unire `Animes` con `Reviews`) per creare dataframe arricchiti pronti per l'analisi. La scelta di Pandas è motivata dalla sua flessibilità e dalla vasta integrazione con librerie di visualizzazione.

Issues

La dimensione di `ratings.csv` (oltre 124 milioni di righe) ha presentato problemi di memoria. Abbiamo dovuto ottimizzare i tipi di dati (es. convertendo `float64` in `float32`) e caricare i dati in chunk per evitare crash del kernel Jupyter.

Requirements

Questo modulo soddisfa direttamente il requisito: "design a (set of) Jupiter Notebook(s) that clean [...] the data".

Limitations

Nonostante l'uso di DuckDB, utile per la gestione di tabelle molto grandi, la lettura e le operazioni su "ratings" sono abbastanza lente e richiedono l'uso di molta RAM.

4. Visualisation & Geospatial Analysis (Seaborn, Plotly, Folium)

Solution (Design and Motivations)

Per soddisfare le esigenze sia dei Fan che dei Giornalisti, abbiamo adottato un approccio ibrido alla visualizzazione:

- **Seaborn & Matplotlib:** Utilizzati per visualizzazioni statiche ad alta qualità (heatmap di correlazione, distribuzioni statistiche), ideali per reportistica giornalistica e pubblicazioni.
- **Plotly:** Utilizzato per grafici interattivi che permettono ai Fan di esplorare i dati (zoom, filter, hover details) direttamente nel notebook.
- **Folium & Geopandas:** Implementati per l'analisi geospaziale, visualizzando la distribuzione della popolarità degli anime o la provenienza dei personaggi su mappe interattive.

Issues

Rendere le mappe di Folium leggibili quando si visualizzano migliaia di punti è stato complesso. Abbiamo risolto utilizzando tecniche di "clustering" dei marker per evitare il sovraffollamento visivo.

Requirements

Questa sezione copre il requisito fondamentale di "visualise the data", fornendo strumenti specifici per l'analisi esplorativa.

Limitations

Le visualizzazioni interattive (Plotly/Folium) aumentano significativamente la dimensione del file `.ipynb`, rendendolo talvolta lento da caricare o renderizzare su GitHub.

5. Use of Generative AI

Come incoraggiato dalle linee guida, abbiamo utilizzato **Gemini** per supportare lo sviluppo:

- **Generazione Codice:** Supporto nella scrittura di query SQL complesse per DuckDB e nella sintassi avanzata di Plotly per grafici multi-layer.
- **Debugging:** Analisi degli errori di merge di Pandas e suggerimenti per l'ottimizzazione della memoria con NumPy.

Il resto del codice creato è stato fatto dal gruppo, che ha ideato la storia e la struttura legata all'organizzazione del progetto.

6. Conclusioni

Il progetto dimostra come l'integrazione di librerie di analisi dati (Pandas/DuckDB) con strumenti di visualizzazione avanzata (Plotly/Folium) possa trasformare dataset eterogenei in una narrazione coerente. Abbiamo fornito strumenti distinti per l'esplorazione ludica (Fan) e l'analisi statistica rigorosa (Giornalisti), superando le sfide poste dalla voluminosità dei dati.

7. Division of Work

Tutti i membri hanno lavorato su tutte le parti della soluzione, collaborando in chiamata Discord, tramite repository Git condiviso.

8. Extra Information

- **Ambiente:** Il progetto è stato eseguito tramite Python 3.13.7+.
- **Setup:** Eseguire `pip install -r requirements.txt` prima di lanciare i notebook. Caricare manualmente prima i dati all'interno di un database Postgres, poiché altrimenti comprometterebbe l'esecuzione del progetto.
- **Configurazione:** Recuperare l'accesso al database tramite il file di configurazione `.env` e inserire le credenziali.
- **Librerie Principali:** `ipython`, `pandas`, `seaborn`, `geopandas`, `folium`, `numpy`, `matplotlib`, `plotly`, `duckdb`, `sqlalchemy`, `psycopg2-binary`, `python-dotenv`.

9. Bibliography

1. Slides Prof. Ciravegna (HCI 2025-2026)
2. Pandas Documentation: <https://pandas.pydata.org/docs/>
3. Plotly Python Graphing Library: <https://plotly.com/python/>
4. DuckDB Documentation: <https://duckdb.org/docs/>
5. Geopandas & Folium Documentation